

Bài toán yêu cầu xây dựng hệ thống AI xử lý văn bản y khoa tự do - ghi chú bác sĩ, giấy xuất viện, kết quả xét nghiệm, hồ sơ EHR - để phát hiện và chuẩn hóa các khái niệm y tế xuất hiện trong văn bản. Hệ thống cần xác định loại khái niệm (triệu chứng, kết quả xét nghiệm, bệnh, thuốc, thông tin bệnh nhân), ánh xạ bệnh với chuẩn ICD-10 và thuốc với chuẩn RxNorm, đồng thời suy luận mối liên hệ ngữ cảnh (phủ định, người nhà, tiền sử) cũng như quan hệ giữa các khái niệm. Đây là bài toán nền tảng cho chuyển đổi số y tế, giúp dữ liệu lâm sàng phi cấu trúc có thể liên thông và khai thác trên quy mô lớn cho chẩn đoán, nghiên cứu dịch tễ và các ứng dụng AI y khoa.

1. Tổng quan

Bài toán tập trung vào việc sử dụng những giải pháp NLP, LLM hay kết hợp agents xây dựng một hệ thống AI có khả năng thực hiện đồng thời: xác định và chuẩn hóa khái niệm y tế chuyên môn và suy luận ontology (Ontological Reasoning) trên dữ liệu y khoa dạng văn bản tự do (free-form clinical text) nhằm xác định quan hệ giữa các khái niệm y tế trong một ngữ cảnh nhất định. Hệ thống AI được cung cấp các cơ sở tri thức y khoa là ICD và RxNorm. Nhiệm vụ của hệ thống là: phát hiện các khái niệm y tế và thông tin bệnh nhân xuất hiện trong văn bản, xác định loại khái niệm (bao gồm triệu chứng, kết quả xét nghiệm, bệnh và thuốc điều trị), thực hiện ánh xạ các khái niệm này với nguồn dữ liệu tương ứng và trả về danh sách các mã định danh phù hợp nhất cho từng khái niệm, và xác định các mối liên hệ giữa các khái niệm này trong đoạn văn. Bài toán cần xử lý hai nhóm giải pháp chính: xác định và chuẩn hóa khái niệm y tế, và suy luận mối liên hệ giữa các khái niệm đã được xác định.

2. Bối cảnh

Trong lĩnh vực y tế, dữ liệu lâm sàng và hồ sơ bệnh án thường được ghi nhận dưới nhiều định dạng và cách diễn đạt khác nhau, phụ thuộc vào cơ sở khám chữa bệnh, chuyên khoa, ngôn ngữ chuyên môn cũng như thói quen nhập liệu của nhân viên y tế. Để đảm bảo khả năng liên thông, thống nhất và khai thác dữ liệu trên quy mô lớn, nhiều hệ thống chuẩn y khoa đã được xây dựng như ICD, SNOMED CT, RxNorm, LOINC, UMLS,... cùng với danh mục dùng chung chứa thông tin bệnh nhân (patient database). Các chuẩn này đóng vai trò như một "ngôn ngữ chung" giúp đồng bộ dữ liệu giữa các bệnh viện, hệ thống bảo hiểm, nền tảng nghiên cứu và các ứng dụng trí tuệ nhân tạo trong y tế. Tuy nhiên, trong thực tế vận hành, phần lớn dữ liệu y khoa vẫn tồn tại dưới dạng văn bản tự do như ghi chú bác sĩ, mô tả triệu chứng, kết luận chẩn đoán hay báo cáo cận lâm sàng, nơi cùng một khái niệm có thể được diễn đạt theo nhiều cách khác nhau, sử dụng từ viết tắt, thuật ngữ địa phương hoặc chứa lỗi chính tả và cấu trúc không chuẩn hóa.

Hiện nay, quá trình chuẩn hóa các khái niệm y tế từ văn bản tự do vẫn là một thách thức lớn đối với các hệ thống xử lý dữ liệu y khoa. Việc ánh xạ chính xác giữa biểu đạt ngôn ngữ tự nhiên và khái niệm chuẩn đòi hỏi mô hình phải hiểu được ngữ cảnh chuyên môn sâu, xử lý hiện tượng đa nghĩa, đồng nghĩa và các biến thể diễn đạt phức tạp trong tiếng nói lâm sàng. Đặc biệt, trong môi trường dữ liệu thực tế, văn bản thường ngắn gọn, thiếu cấu trúc, chứa nhiều ký hiệu chuyên ngành hoặc kết hợp đồng thời nhiều thông tin bệnh lý trong cùng một câu. Những khó khăn này làm hạn chế khả năng khai thác dữ liệu phục vụ hỗ trợ chẩn đoán, nghiên cứu dịch tễ, thống kê y tế và xây dựng các hệ thống AI y khoa quy mô lớn. Những hệ thống này nếu không thể kết nối được với chuẩn y tế đã tồn tại thì không thể hiệu quả. Vì vậy, bài toán đang trở thành một hướng nghiên cứu và ứng dụng quan trọng, đóng vai trò nền tảng cho quá trình chuyển đổi số và phát triển trí tuệ nhân tạo trong lĩnh vực chăm sóc sức khỏe.

3. Mô tả bài toán

3.1 Input

Input của bài toán là một đoạn văn bản y khoa dạng tự do (free-form text). Input có thể tồn tại ở các dạng: kết quả khám lâm sàng, giấy xuất viện, ghi chú của bác sĩ, kết quả chẩn đoán hình ảnh, kết quả xét nghiệm, hồ sơ sức khỏe điện tử (EHR), hoặc các ghi chú lâm sàng khác. Dữ liệu đầu vào có thể chứa: thuật ngữ y khoa, viết tắt, thông tin bệnh nhân và nhiều loại khái niệm y tế khác nhau xuất hiện đồng thời trong cùng một văn bản. VD: "Bệnh nhân bị bệnh 1 tuần nay, ho đờm xanh, tức ngực, đau thượng vị, ợ hơi, được chẩn đoán mắc bệnh trào ngược dạ dày - thực quản."

3.2 Output

Output của bài toán là danh sách các khái niệm y tế được phát hiện trong văn bản cùng với nội dung khái niệm y tế được nhận diện, loại khái niệm y tế, danh sách các candidate mapping tương ứng và mối liên hệ giữa các khái niệm.

Mỗi khái niệm y tế trong output bao gồm các trường sau:

- text: cụm từ trong input mà hệ thống xác định là một khái niệm y tế
- position: 1 list gồm 2 phần tử dạng số, để chỉ vị trí bắt đầu và kết thúc của cụm từ hoặc đoạn văn bản đã xác định phía trên trong input (mặc định vị trí tính từ 0 đến n - 1, trong đó n là độ dài đoạn văn bản input tính theo ký tự).
- type: loại khái niệm y tế, bao gồm 1 trong các nhãn như sau: • **TRIỆU_CHỨNG**: Tên triệu chứng bệnh nhân mắc phải • **TÊN_XÉT_NGHIỆM**: Tên xét nghiệm bệnh nhân thực hiện • **KẾT_QUẢ_XÉT_NGHIỆM**: Kết quả xét nghiệm bệnh nhân thực hiện, bao gồm giá trị và đơn vị của xét nghiệm • **CHẨN_ĐOÁN**: Tên chẩn đoán của bác sĩ về bệnh mà bệnh nhân mắc phải • **THUỐC**: Tên thuốc mà bệnh nhân điều trị
- assertions: các mối liên hệ của khái niệm y khoa (ở đây chỉ giới hạn trong **CHẨN_ĐOÁN**, **THUỐC** và **TRIỆU_CHỨNG**) trong bối cảnh văn bản y khoa được cung cấp, được cung cấp dưới dạng 1 list bao gồm các chuỗi thể hiện mối liên hệ này. List này có tối đa 3 phần tử như sau: • **"isNegated"**: khái niệm bị phủ định trong văn bản (VD: "không ho") • **"isFamily"**: khái niệm có liên quan đến tình trạng của người nhà, họ hàng với bệnh nhân (VD: "bố bệnh nhân xuất hiện trường hợp đau bụng tương tự") • **"isHistorical"**: khái niệm có liên quan đến tiền sử bệnh nhân (VD: "có tiền sử hen suyễn")
- candidates: danh sách các candidate mapping mà hệ thống dự đoán. Các candidate này chỉ được xét trên các loại khái niệm là **CHẨN_ĐOÁN** và **THUỐC**. Mỗi phần tử trong danh sách là mã của chuẩn y tế tương ứng (mã ICD với bệnh, RxNorm với thuốc) của khái niệm.
- 1 ví dụ của bài toán được thể hiện như sau:

Input:

"Bệnh nhân nam 70 tuổi bị bệnh 1 tuần nay, ho đờm xanh, tức ngực, đau thượng vị, ợ hơi, được chẩn đoán mắc bệnh trào ngược dạ dày - thực quản. Bệnh nhân có tiền sử sử dụng Chlorpheniramine 0.4 MG/ML, Capsaicin 0.38 MG/ML, đã tiến hành tổng phân tích tế bào máu bằng máy lazer (tbm): WBC:14,43; NEUT% (Tỷ lệ % bạch cầu trung tính):76,4; LYPH% (Tỷ lệ bạch cầu lympho):12,8;"

Output bài toán bao gồm:

- **CHẨN_ĐOÁN**: "bệnh trào ngược dạ dày - thực quản" - mã ICD bao gồm K21.0, K21.9

- **TRIỆU_CHỨNG**: "ho đờm xanh", "tức ngực", "đau thượng vị", "ợ hơi"
- **TÊN_XÉT_NGHIỆM**: "TWBC", "NEUT% (Tỷ lệ % bạch cầu trung tính)", "LYPH% (Tỷ lệ bạch cầu lympho)"
- **KẾT_QUẢ_XÉT_NGHIỆM**: "14,43", "76,4", "12,8"
- **THUỐC**: "Chlorpheniramine 0.4 MG/ML" - mã RxNorm 360047, "Capsaicin 0.38 MG/ML" - mã RxNorm 1660761; assertion: "isHistorical"

Lưu ý: Các giá trị liên quan đến thông tin cá nhân (tên, tuổi, địa chỉ, sdt) đều là những giá trị synthetic, không phải các thông tin người thật

4. Dữ liệu bài toán

Về CSDL chuẩn y tế cho candidate mapping: sử dụng chuẩn ICD-10 cho các loại bệnh và RxNorm cho các loại thuốc.

Các thí sinh sẽ được cung cấp 1 bộ dữ liệu như sau:

Tập test: bao gồm 100 bản ghi. Thí sinh sẽ được cung cấp tập test là 1 file test.zip. Trong file zip là 1 folder input bao gồm chỉ các file .txt có cấu trúc như sau:

```
test/
├── input/
│   ├── 1.txt      # Văn bản đầu vào của bản ghi 1
│   ├── 2.txt      # Văn bản đầu vào của bản ghi 2
│   ├── ...
│   └── 100.txt
```

Các file .txt là các văn bản dạng free-form text làm input của bài toán. Lưu ý: các văn bản free-form text đều chứa nhiều hơn 1 khái niệm.

Với mỗi file .txt, thí sinh cần trả về 1 output là file .json tương ứng, mỗi file là 1 list các dictionary với các trường thể hiện dạng list dictionary của danh sách các khái niệm y tế mang các thông tin output (chi tiết sẽ được nêu ví dụ tại phần 5a).

Các thí sinh cần sử dụng các giải pháp nằm ngoài lời giải chính để tạo thêm dữ liệu nhằm huấn luyện mô hình.

5. Thể thức

Vòng 1, các thí sinh dự thi nộp kết quả dự đoán dưới dạng file JSON theo đúng format do Ban Tổ chức (BTC) quy định. File nộp bao gồm một file output.zip có cấu trúc sau khi giải nén như sau:

```
output/
├── 1.json      # Nhãn của bản ghi 1
└── 2.json      # Nhãn của bản ghi 2
```

```
└─ ...
└─ 100.json
```

Chi tiết dạng json trong output sẽ được nêu ở ví dụ dưới.

Lưu ý:

- Trước khi vòng 1 kết thúc, BTC yêu cầu top ~15 đội gửi trước source code riêng để thực hiện dựng lại và đánh giá trên dữ liệu private test. Việc này nhằm tránh tình trạng gian lận nộp file hard code output với input được cung cấp.
- Source code bao gồm:
 - tất cả các file code của nhóm (data processing, training, inference, ...)
 - data nhóm sử dụng
 - model weights
 - 1 file readme hướng dẫn cài đặt
 Nếu BTC không thể cài đặt được code của nhóm thì, nhóm thi sẽ được liên lạc riêng để hỗ trợ trong 1 khoảng thời gian nhất định. Nếu nhóm không thể cung cấp hỗ trợ kịp thời sẽ bị loại.
- VD input-output vòng 1:

Input:

```
> 'Danh sách thuốc trước nhập viện chính xác và đầy đủ.
1. amlodipine 10 mg po daily
2. aspirin 81 mg po daily
3. metoprolol succinate xl 50 mg po daily
4. guaifenesin ml po q6h:prn điều trị ho
5. nystatin oral suspension 5 ml po qid:prn điều trị đau nhức
6. acetaminophen 325-650 mg po q6h:prn điều trị sốt đau
7. pravastatin 40 mg po daily
8. docusate sodium 100 mg po bid điều trị táo bón
9. senna 8.6 mg po bid:prn điều trị táo bón
10. clonazepam 0.5 mg po qam:prn điều trị lo âu
11. clonazepam 1.5 mg po qhs điều trị lo âu mất ngủ'
```

Output:

```
[
  {
    "text": "amlodipine 10 mg po daily",
    "type": "THUỐC",
    "candidates": ["308135"],
    "assertions": ["isHistorical"],
    "position": [58, 83]
  },
  {
    "text": "aspirin 81 mg po daily",
    "type": "THUỐC",
    "candidates": ["243670"],
    "assertions": ["isHistorical"],
    "position": [89, 111]
  },
]
```

```
{
  "text": "metoprolol succinate xl 50 mg po daily",
  "type": "THUỐC",
  "candidates": ["866436"],
  "assertions": ["isHistorical"],
  "position": [117, 155]
},
{
  "text": "guaifenesin ml po q6h:prn",
  "type": "THUỐC",
  "candidates": ["392085"],
  "assertions": ["isHistorical"],
  "position": [161, 186]
},
{
  "text": "ho",
  "type": "TRIỆU_CHỨNG",
  "assertions": [],
  "position": [196, 198]
},
{
  "text": "nystatin oral suspension 5 ml po qid:prn",
  "type": "THUỐC",
  "candidates": ["7597"],
  "assertions": ["isHistorical"],
  "position": [204, 244]
},
{
  "text": "đau nhức",
  "type": "TRIỆU_CHỨNG",
  "assertions": [],
  "position": [254, 262]
},
{
  "text": "acetaminophen 325-650 mg po q6h:prn",
  "type": "THUỐC",
  "candidates": ["313782"],
  "assertions": ["isHistorical"],
  "position": [268, 303]
},
{
  "text": "sốt đau",
  "type": "TRIỆU_CHỨNG",
  "assertions": [],
  "position": [313, 320]
},
{
  "text": "pravastatin 40 mg po daily",
  "type": "THUỐC",
  "candidates": ["904475"],
  "assertions": ["isHistorical"],
  "position": [326, 352]
},
{
```

```
"text": "docusate sodium 100 mg po bid",
"type": "THUỐC",
"candidates": ["1099279"],
"assertions": ["isHistorical"],
"position": [358, 387]
},
{
  "text": "táo bón",
  "type": "TRIỆU_CHỨNG",
  "assertions": [],
  "position": [397, 404]
},
{
  "text": "senna 8.6 mg po bid:prn",
  "type": "THUỐC",
  "candidates": ["312935"],
  "assertions": ["isHistorical"],
  "position": [410, 433]
},
{
  "text": "táo bón",
  "type": "TRIỆU_CHỨNG",
  "assertions": [],
  "position": [443, 450]
},
{
  "text": "clonazepam 0.5 mg po qam:prn",
  "type": "THUỐC",
  "candidates": ["197527"],
  "assertions": ["isHistorical"],
  "position": [457, 485]
},
{
  "text": "lo âu",
  "type": "TRIỆU_CHỨNG",
  "assertions": [],
  "position": [495, 500]
},
{
  "text": "clonazepam 1.5 mg po qhs",
  "type": "THUỐC",
  "candidates": ["197528"],
  "assertions": ["isHistorical"],
  "position": [507, 531]
},
{
  "text": "lo âu",
  "type": "TRIỆU_CHỨNG",
  "assertions": [],
  "position": [541, 546]
},
{
  "text": "mất ngủ",
  "type": "TRIỆU_CHỨNG",
```

```

    "assertions": [],
    "position": [547, 554]
  }
]

```

6. Metric đánh giá

Kết quả của thí sinh sẽ được tính trên tập test theo các metric sau:

- Xét theo xác định tên khái niệm: sử dụng Word Error Rate (WER) trên trường text.
- Xét theo xác định các assertions giữa khái niệm: sử dụng metric là độ tương đồng Jaccard (Jaccard similarity) với các bệnh, thuốc và triệu chứng tương ứng, lấy trung bình tất cả các giá trị này thành 1 điểm $J(\text{assertion})$
- Xét theo xác định candidates trong khái niệm: sử dụng metric giống với xác định assertion
- Kết quả cuối cùng được tính điểm theo công thức:

$$\text{final_score} = 0.3 \cdot \text{text_score} + 0.3 \cdot \text{assertions_score} + 0.4 \cdot \text{candidates_score}$$

Trong đó, với mỗi i là 1 sample trong tập test, mỗi k là 1 candidate trong sample i , $\text{WER}(i)$ là WER của trường text trong sample i , $\text{ground_truth}(k)$, $\text{prediction}(k)$ lần lượt là tập ground truth, prediction của candidate k trong sample i , $J_X(i)$ là độ tương đồng Jaccard của sample i xét trên trường X tương ứng của output:

$$\text{text_score} = \frac{\sum_{i \in \text{test}} (1 - \text{WER}(i))}{\text{len}(\text{test})}$$

$$\text{assertions_score} = \frac{\sum_{i \in \text{test}} J_{\text{assertions}}(i)}{\text{len}(\text{test})}$$

$$\text{candidates_score} = \frac{\sum_{i \in \text{test}} J_{\text{candidates}}(i) \cdot (\sum_{k \in i} (\text{len}(\text{ground_truth}(k)) + 1))}{\sum_{i \in \text{test}} \sum_{k \in i} (\text{len}(\text{ground_truth}(k)) + 1)}$$

$$J_X(i) = 1 \text{ nếu } \text{len}(\text{ground_truth}_X(i)) = 0 \text{ và } \text{len}(\text{prediction}_X(i)) = 0$$

$$J_X(i) = 0 \text{ nếu } \text{len}(\text{ground_truth}_X(i)) = 0 \text{ và } \text{len}(\text{prediction}_X(i)) \neq 0$$

$$J_X(i) = \frac{|\text{ground_truth}_X(i) \cap \text{prediction}_X(i)|}{|\text{ground_truth}_X(i) \cup \text{prediction}_X(i)|} \text{ trong các trường hợp còn lại}$$

- **Lưu ý:** Trong trường hợp đoán đúng phần text của khái niệm nhưng sai loại (VD: đoán **CHẨN_ĐOÁN** nhưng ground truth là **TRIỆU_CHỨNG**), khái niệm sẽ bị tính 2 lần (do tạo ra 1 khái niệm mới so với ground truth) và mỗi lần đều được tính 0 điểm với cả 3 loại metric.

7. Tài nguyên

Cấu hình máy được sử dụng:

Thí sinh tự chuẩn bị tài nguyên tính toán. Tuy nhiên, với những giải pháp LLM/agent chỉ cho phép thí sinh self-host model mà không được sử dụng API ngoài, model self-host có độ lớn tối đa là 9B params.